Optimización y explicabilidad

Optimización

Definición

La optimización de hiperparámetros es el proceso de ajustar los parámetros de un modelo de ML que no se aprenden directamente de los datos, sino que deben configurarse antes del entrenamiento para mejorar el rendimiento.

Estos hiperparámetros afectan la capacidad del modelo para aprender patrones y pueden influir en la precisión, la velocidad y la capacidad de generalización del modelo.

Ejemplo de hiperparámetros en LightGBM:

`learning_rate` Controla la velocidad de actualización de los pesos en cada iteración.

`num_leaves` Afecta la complejidad del árbol de decisión.

`n_estimators` Número de árboles en el modelo de boosting.

Técnicas de optimización

	GridSearch	Random Search	Optuna
¿Cómo funciona?	• Especifica un conjunto de valores de hiperparámetros para cada parámetro. • Entrena el modelo para cada posible combinación de estos valores. • Utiliza validación cruzada para evaluar el rendimiento de cada combinación. • Selecciona la combinación que ofrece el mejor rendimiento	• Especifica un rango de valores de hiperparámetros para cada parámetro. • Evalúa un número definido por el usuario de combinaciones de hiperparámetros dentro del espacio de búsqueda y determina la combinación que ofrece el mejor rendimiento. • Utiliza validación cruzada. • Selecciona la combinación que proporciona el mejor rendimiento.	1. Define el objetivo a optimizar. Ej. El AUC 2. Se especifican los rangos de búsqueda. 3. Toma una primera selección de hiperparámetros de manera aleatoria 4. Utiliza Tree-structured Parzen Estimators (TPE) para encontrar la mejor combinación de hiperparámetros 5. Después de cada trial, tomar parámetros basándose en la experiencia pasada. 6. Cuando ejecuta los intentos predefinidos devuelve la mejor combinación
¿Cómo funciona?	• Exhaustivo • Fácil de implementar.	• Más eficiente.Explora un mayor rango de hiperparámetros sin llegar a evaluar todas las combinaciones • Funciona mejor con datasets grandes o número elevado de hiperparámetros	• Supone un ahorro de tiempo • Es una búsqueda inteligente que se apoya en los intentos pasados • Fácil de usar • escalable
¿Cómo funciona?	• Computacionalmente costoso • No escala bien con muchos hiperparámetros o datasets grandes	• Se podría perder el óptimo al ser aleatorio	• Computacionalmente costoso • Black box • Ha de ser configurado cuidadosamente • No garantiza llegar al óptimo

Explicabilidad

En muchas ocasiones probamos modelos que mejorar mucho las métricas (AUC, kappa,...) sin embargo se acaban convirtiendo en black-box es decir en este proceso perdemos explicabilidad.

XAI (Explainable AI) es un conjunto de métodos y técnicas que buscan hacer los modelos de IA más interpretables y comprensibles para los humanos. Su objetivo es explicar cómo y por qué un modelo toma ciertas decisiones, lo que ayuda a generar confianza y mejorar la transparencia en aplicaciones de ML e IA.

Existen técnicas de interpretabilidad y son a posteriori, es decir una vez hecho el modelo.

Las principales son: Dalex, Shap, LIME.

Explicabilidad local y global

Model Exploration Stack

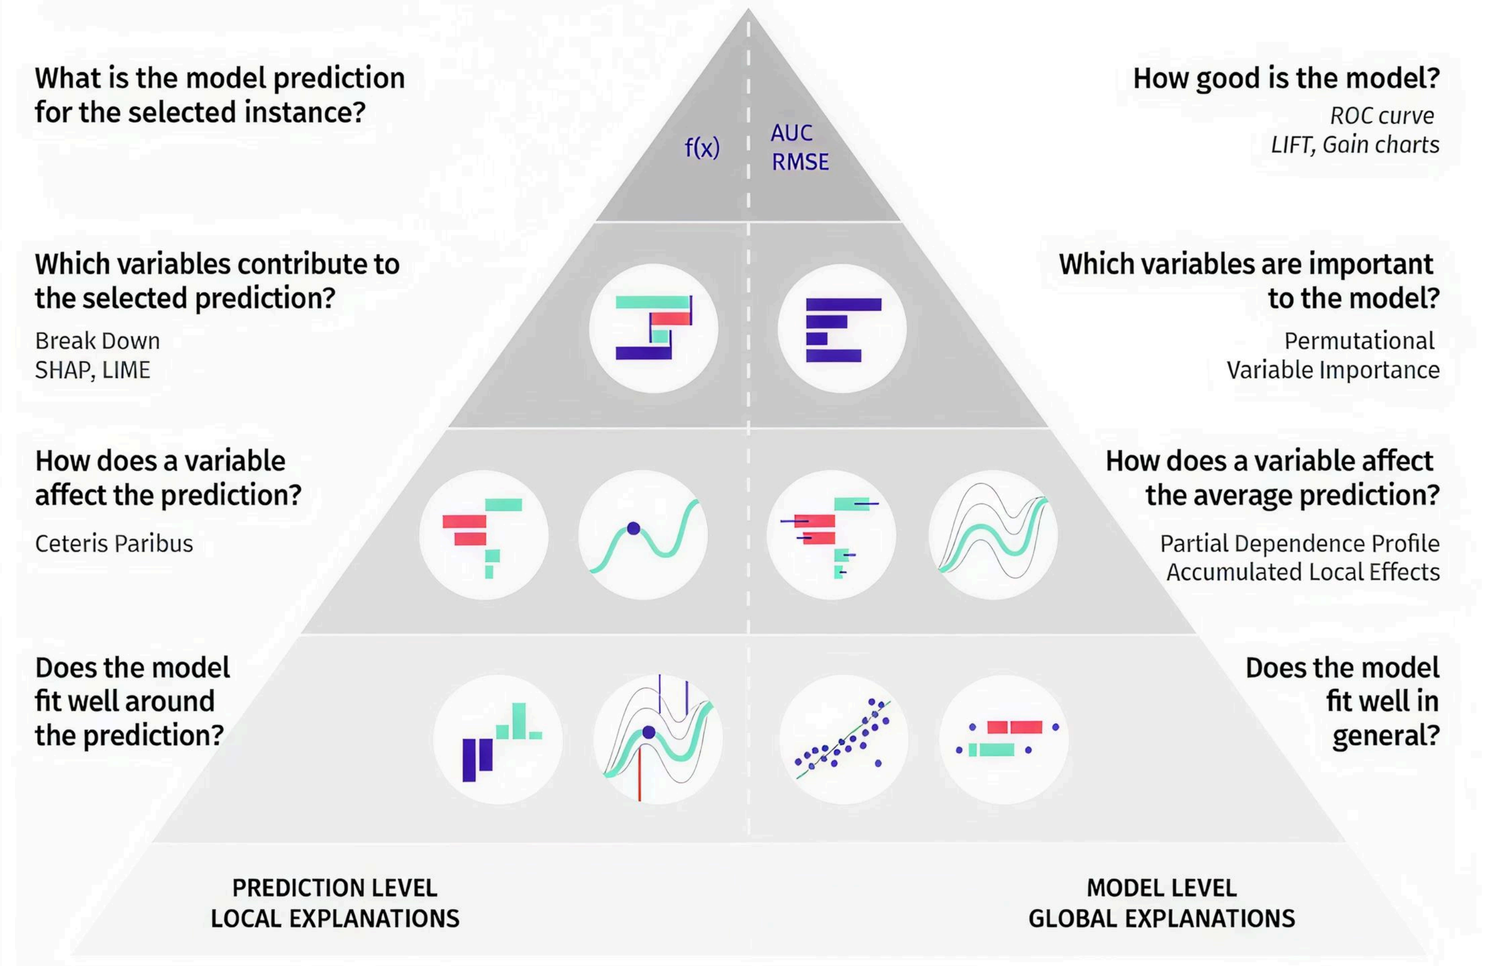

Biecek, P. and Burzykowski, T.

Resumen

Algoritmo	Tipo	Ventajas	Desventajas
Regresión Lineal	Regresión	Simple, rápida, fácil de interpretar.	No captura relaciones no lineales.
Regresión Polinómica	Regresión	Permite modelar relaciones más complejas.	Mayor riesgo de sobreajuste con grados elevados.
Regresión Logística	Regresión	Fácil de interpretar	No captura relaciones no lineales.
Árboles de Decisión	Ambos	Interpretables, no requieren preprocesamiento.	Sensibles al sobreajuste sin poda.
Random Forest	Ambos	Reduce sobreajuste, alto rendimiento.	Más costoso computacionalmente.
SVM (Máquinas de Soporte Vectorial)	Clasificación	Funciona bien con datos no lineales.	Difícil de ajustar en conjuntos grandes
Naïve Bayes	Clasificación	Rápido, eficiente para datos de texto.	Supone independencia entre las variables.
Redes Neuronales (MLP)	Ambos	Potentes para patrones complejos.	Computacionalmente costosas. Dificil de interpretar
Gradient Boosting (XGBoost, LightGBM, CatBoost)	Ambos	Precisión alta, manejo eficiente de datos grandes.	Puede ser difícil de interpretar.

Algoritmo	Tipo	Ventajas	Desventajas
K-Means	Clustering	Rápido, fácil de interpretar	Necesita definir el número de grupos (K) manualmente.
DBSCAN	Clustering	Detecta grupos de forma automática sin necesidad de K. funciona bien con datos con ruido y valores atípicos.	Sensible a la elección de parámetros (eps, min_samples).
Hierarchical Clustering	Clustering	Genera un dendrograma interpretable.	Costoso en grandes conjuntos de datos.
PCA (Análisis de Componentes Principales)	Reducción de Dimensionalidad	Reduce la cantidad de variables manteniendo la información clave.	Puede perder interpretabilidad en datos con mucha variabilidad.
t-SNE	Reducción de Dimensionalidad	Excelente para visualizar datos en 2D o 3D.	No funciona bien con grandes volúmenes de datos.
Apriori	Reglas de Asociación	Fácil de entender, genera reglas interpretables.	Computacionalmente costoso en conjuntos grandes.
FP-Growth	Reglas de Asociación	Más rápido que Apriori, no necesita generar candidatos.	Puede ser difícil de interpretar en datos complejos.
Association Rules	Reglas de Asociación	Encuentra patrones en datos transaccionales y genera reglas útiles.	Necesita definir métricas como **soporte, confianza y lift**