PROYECTO MACHINE LEARNING

Predicción de Recompra

de Clientes en Retail Online

Un modelo que identifica qué clientes van a volver — antes de que lo hagan.

Dataset: Online Retail II | 24 meses | 1M+ transacciones | 43 países

El punto de partida: ¿qué teníamos?

1.067.371
transacciones registradas

5.942
clientes únicos

5.305
productos distintos

43
países

Decisiones de limpieza

67.242	duplicados eliminados (misma transacción registrada dos veces)
22,1%	sin Customer ID → compras de invitados. Se conservan marcados como grupo especial
3.393	ajustes internos de inventario eliminados (sin precio ni cliente)
84%	del tráfico proviene de UK → la variable país se excluye por falta de varianza
19.102	devoluciones separadas → no se consideran ventas, pero sí influyen en el perfil del cliente
5 facturas	con volúmenes imposibles (+74.000 uds) eliminadas por ser netas cero o ajustes

¿Cómo sabe el modelo quién va a volver?

1

Resumimos el pasado de cada cliente

Con 24 meses de compras calculamos 5 indicadores por cliente: tiempo sin comprar, cuántas veces compró, cuánto gastó, con qué frecuencia y su tasa de devolución.

2

Definimos quién "volvió"

Dividimos los datos en dos ventanas: los primeros 18 meses para aprender, los últimos 6 para comprobar. Si el cliente compró en esos últimos 6 meses → volvió (1). Si no → no volvió (0).

3

El modelo aprendió el patrón

Con esos datos, el algoritmo identificó qué combinación de indicadores distingue a un cliente que va a volver del que no. El resultado es una probabilidad entre 0 y 1 para cada cliente.

Los 5 indicadores clave

Recency

Días sin comprar

Nº de compras

Líneas de pedido históricas

Gasto total

Revenue acumulado (£)

Cadencia

Días medios entre pedidos

Tasa devolución

% pedidos devueltos

HistGradientBoosting

El modelo: resultados y capacidad predictiva

AUC

0.864

Optuna · HistGradientBoosting

Probamos 3 optimizadores
(Random Search, Grid Search, Optuna)
y 4 algoritmos distintos.

¿Qué significa AUC 0.872 en la práctica?

2.0×	más eficiente que contactar al azar en el top 10% de clientes (curva Lift)
75%	de las ventas futuras capturadas contactando a menos del 40% de la base
52/48	balance perfecto entre compradores y no compradores — sin necesitar ajuste

¿Qué variable influye más en si un cliente vuelve? (DALEX — importancia global)

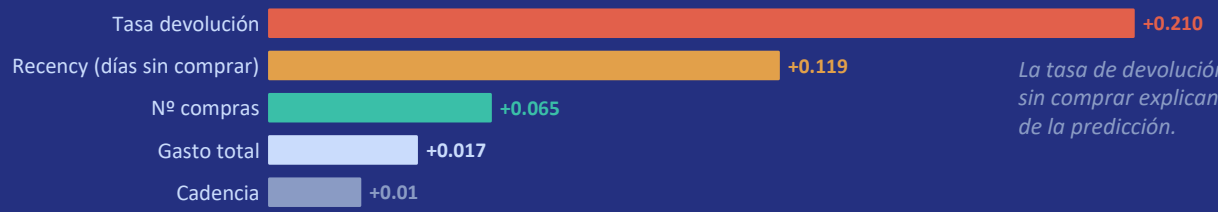

La tasa de devolución y el tiempo sin comprar explican la mayoría de la predicción.

Radiografía de nuestra base de clientes

K-Means identifica 4 perfiles naturales + el grupo de compradores anónimos

VIPs

C3

Prob. recompra

91%

Compra masiva y reciente.
El motor de ingresos.

Fieles

C2

Prob. recompra

58%

Buenos tickets pero
pedidos espaciados.

Indecisos

C1

Prob. recompra

49%

Frecuentes pero con alta
tasa de devolución (36%).

Desconectados

C0

Prob. recompra

26%

Una compra hace
más de 9 meses.

Invitados

–

Prob. recompra

N/A

Compradores anónimos.
Oportunidad de captación.

¿Qué hacemos con cada segmento?

El modelo nos dice a quién priorizar — el clustering nos da el mensaje correcto

VIPs Programa de fidelización exclusivo	**Email / App VIP**	No necesitan descuentos, necesitan trato preferente. El objetivo es maximizar su valor de vida.
Fieles Cupón de reactivación temporal	**Email + Retargeting**	Acortar el ciclo de compra. Son clientes sanos pero lentos — un empujón en el momento correcto.
Indecisos Encuesta de satisfacción + soporte	**Atención al cliente**	Las devoluciones son un coste oculto. Hay que sanear la relación antes de intentar vender más.
Desconectados Campaña de última oportunidad	**Social Ads / Email**	Inversión mínima. Solo vale la pena si el coste de recuperación es menor que el valor esperado.
Invitados Descuento por registro	**Pop-up en el checkout**	Convertir un anónimo en cliente identificado elimina el coste de captación futuro. 22% del tráfico.

Lo que conseguimos

- Modelo con AUC 0.864 — sin sobreajuste
- 2.0× de eficiencia vs contacto aleatorio
- 5 segmentos con acción diferenciada
- 22% de tráfico anónimo con acción específica
- Explicabilidad total variable por variable

Proyecto: Online Retail II
Algoritmo: HistGradientBoosting · AUC 0.864

Próximos pasos

01 Ampliar el espacio de búsqueda de Optuna

Con más trials y rangos más amplios de hiperparámetros, Optuna puede superar el AUC 0.864, aunque podría empeorar, ya que hemos tenido AUC: 0.88 en anteriores trials

02 Incorporar la variable país con OHE

Aunque UK domina (84%), los clientes internacionales podrían tener patrones distintos. Probar el modelo con y sin OHE de país para ver el impacto real en AUC.

03 Modelo de forecasting de revenue

Con la variable revenue_mensual ya construida, se puede aplicar Prophet o ARIMA para predecir la demanda futura por periodos — útil para planificación de inventario y campañas.
24meses -> Pocos datos para captar estacionalidad

04 Objetivo final: Automatización del scoring

Poner el modelo en producción para generar una probabilidad de recompra por cliente cada mes de forma automática, integrándola con la herramienta de CRM.